

INSTITUTO NACIONAL DE TELECOMUNICAÇÕES

MESTRADO EM TELECOMUNICAÇÕES
TP546 - INTERNET DAS COISAS E REDES VEICULARES.

RELATÓRIO DA ATIVIDADE Nº04

Prevenção contra colisões com câmeras embarcadas em veículos

Alunos:

Eylen Jhuliana Mercado Ontiveros

Everton Vilhena Cardoso

Eylen Jhuliana Mercado Ontiveros

Everton Vilhena Cardoso

RELATÓRIO DA ATIVIDADE Nº04

Prevenção contra colisões com
câmeras embarcadas em veículos

17 de outubro, 2024

1 Resumo

As redes veiculares são cruciais para a comunicação entre veículos e infraestruturas rodoviárias. A utilização de câmeras nessas redes oferece um olhar abrangente do ambiente ao redor, essencial para a detecção de obstáculos e condições da estrada. Este relatório busca apresentar as aplicações do uso de câmeras como sensores, explicando como elas funcionam. Nosso foco será nos sistemas de anticolidões, nos quais as câmeras serão usadas como sensores vitais, pois fornecem dados em tempo real para evitar acidentes, garantindo uma condução mais segura.

2 Introdução

Um sistema de prevenção de colisões é uma importante ferramenta de segurança projetada para ajudar a evitar acidentes, proporcionando suporte aos motoristas em momentos críticos. Esses sistemas empregam uma variedade de tecnologias avançadas, incluindo câmeras, GPS, sensores de força G, radar, laser e inteligência artificial com uso da visão computacional.

Essas tecnologias trabalham em conjunto para monitorar constantemente o ambiente ao redor do veículo e também o estado do próprio. Por exemplo, as câmeras capturam imagens do tráfego, enquanto os sensores de força G medem as forças envolvidas durante a condução, permitindo ao sistema avaliar o comportamento do veículo em diferentes situações.

Os dados coletados por esses dispositivos são processados por computadores integrados ou por redes veiculares VANETs, que analisam as informações em tempo real. Com base nessa análise, o sistema é capaz de detectar potenciais perigos, como a aproximação de outros veículos ou obstáculos na via. Quando um risco é identificado, o sistema pode tomar medidas corretivas, como alertar o motorista com avisos sonoros ou visuais, ou até mesmo intervir automaticamente, reduzindo a velocidade do veículo ou ativando os freios para evitar uma colisão.

Assim, esses sistemas de prevenção de colisões não apenas aumentam a segurança dos motoristas, mas também contribuem para a proteção de passageiros, pedestres e outros veículos na estrada, ajudando a reduzir a ocorrência de acidentes e suas consequências.

Este trabalho tem como objetivo focar no estudo dos Sistemas de Prevenção de Colisão, apresentando suas características e como podem ser.

3 Desenvolvimento

3.1 O que é um sistema de prevenção de colisões?

Um sistema de prevenção de colisões (CAS) emprega vários sensores, como câmeras ou lasers para detectar possíveis colisões. Ele alerta o motorista com avisos e pode até mesmo acionar os freios automaticamente. Também conhecido como sistema pré-colisão ou sistema de assistência ao motorista, o CAS visa prevenir acidentes.

Abaixo, exemplificaremos quais aplicações estão envolvida dentro do sistema de prevenção de colisões (CAS), por exemplo:

- Forward collision alert (FCW) - Aumenta a sua segurança ao reduzir o risco de embates pela traseira, um dos tipos mais comuns de acidentes de automóvel, especialmente em condições de tráfego intenso. [i]


Figura 1: Forward Collision Warning System for Automotive.



Fonte: Extraído de Data Bridge Market Research. (2019)

- Lane Departure Warning (LDW) - É um sistema que ajuda a prevenir colisões ao alertar o motorista quando um pneu toca em um marcador de faixa, utilizando indicadores visuais ou sonoros e, em alguns casos, vibrações no volante ou no assento. Esse sistema não ativa quando o pisca-pisca está ligado. Alguns veículos contam ainda com a assistência de manutenção de faixa, que, se detectar uma possível saída de faixa e o motorista não reagir, orienta suavemente o carro de volta para a faixa. [iv]


Figura 2: Lane Departure Warning (LDW).



Fonte: Extraído de Detroit Diesel Corporation. (2020)

- Pedestrian and Cyclist Collision Warning (PCW) - É uma das inovações mais importantes na tecnologia veicular, ajudando a prevenir ferimentos graves ou fatais a pedestres e ciclistas, especialmente em áreas urbanas. O PCW proporciona aos motoristas o tempo de reação necessário para evitar colisões, tornando-se uma ferramenta essencial para frotas comerciais e um sistema de prevenção de acidentes amplamente difundido em pesquisas científicas. [vi]

Figura 3: Volvo's anti-collision system extended to cyclists.



Fonte: Extraído de fourteenislands.com, Laurent Pignon. (2013)

- Pothole Detection and Warning System - Auxilia os motoristas a evitar buracos na estrada, fornecendo avisos prévios usando a técnica de aprendizado de máquina. O aviso pode ser como uma campainha enquanto o veículo se aproxima de um buraco. Este conceito pode ser expandido para criar veículos que detectam lombadas e outras irregularidades na estrada, reduzindo efetivamente o problema do aumento de acidentes causados por buracos. [vii]

Figura 4: Comparação de resultados entre YOLOv3 (esquerda) e YOLOv4 (direita).



Fonte: Extraído de Pranjal A. Chitale et al. (2021)

O CAS pode mitigar a gravidade quando os acidentes ocorrem. Com o seu maior uso, pode ser significativamente menor ou até nulo o acontecimento de um incidente envolvendo veículos.

3.2 Funcionamento de um sistemas de prevenção de colisões

No contexto da detecção de colisão de veículos, os sistemas de visão computacional utilizam uma infinidade de técnicas para interpretar e responder às informações visuais dinâmicas presentes no ambiente ao redor do veículo.

O processo de prevenção de colisão concentram-se principalmente em áreas como:

- Captura de imagens

O sistema de prevenção de colisões começa com a captura de imagens de alta resolução em tempo real por meio de câmeras instaladas nas partes dianteira, lateral ou traseira do veículo. As câmeras fornecem uma visão ampla do ambiente funcionando como os “olhos” do veículo fornecendo uma visão contínua do ambiente, capturando uma série de imagens em alta velocidade, geralmente entre 30 e 60 quadros por segundo (fps), o que garante uma análise contínua e fluida da estrada e dos obstáculos (Li et al., 2019).

- Processamento de imagens e extração de características

O uso de câmeras como sensores em redes veiculares vem se tornando cada vez mais comum, devido à capacidade dessas câmeras de capturar uma grande quantidade de informações visuais do ambiente ao redor dos veículos.

No entanto, para que essas imagens sejam úteis em um contexto de rede veicular, é necessário realizar o processamento dessas imagens e a extração de características que possam ser analisadas e interpretadas em tempo real. Isso se dá através de algoritmos de visão computacional e redes neurais convolucionais (CNNs), que analisam os padrões visuais para detectar objetos como pedestres, veículos, ciclistas, e outros obstáculos (Liu et al., 2021). Esses algoritmos são projetados para processar dados brutos de imagem e transformá-los em informações significativas que podem ser utilizadas para diversas aplicações, como sistemas de assistência ao condutor, navegação autônoma e prevenção de acidentes.

- Reconhecimento e classificação de objetos

A detecção de objetos a partir de imagens de câmeras envolve tanto a classificação quanto a localização de cada objeto de nosso interesse. É uma tarefa complexa porque não sabemos de antemão onde esses objetos podem aparecer na imagem ou quais podem ser seus tamanhos. Como resultado, o problema de detecção de objetos torna-se bastante desafiador.

Com o surgimento da aprendizagem profunda (AP), os métodos de detecção de objetos usando AP superaram muitos métodos tradicionais em termos de precisão e velocidade. Há muitos sistemas que estão usando a aprendizagem profunda como um método de detecção

porque eles aprimoram os resultados da detecção de uma forma computacionalmente inteligente. Em termos gerais, há duas abordagens para a detecção de objetos de imagem usando a Deep Learning (DL).

Uma abordagem é baseada em propostas de regiões. A R-CNN mais rápida é um exemplo. Esse método primeiro executa toda a imagem de entrada por meio de algumas camadas convolucionais para obter um mapa de recursos. Em seguida, há uma rede de proposta de região separada, que usa esses recursos convolucionais para propor possíveis regiões para detecção. Por fim, o restante da rede classifica essas regiões propostas. Como há duas partes na rede, uma para prever a caixa delimitadora e a outra para a classificação, esse tipo de arquitetura pode reduzir significativamente a velocidade de processamento.

Outro tipo de abordagem usa uma rede para prever regiões potenciais e para a classificação de rótulos. Um exemplo é o YOLO (You Only Look Once). YOLO é um método de detecção de objetos de passada única (single pass) que utiliza uma rede neural convolucional como extrator de características (features) (Redmon et al., 2016). O YOLO é rápido, mas às vezes pode não detectar objetos pequenos na imagem (Redmon y Farhadi, 2017)

- Detecção de Perigo e Cálculo de Distância

Além da detecção de objetos, o sistema usa as informações capturadas pelas câmeras para calcular a distância entre o veículo e os objetos identificados. Esse cálculo é baseado em algoritmos de visão estéreo (quando duas câmeras são usadas) ou técnicas de fluxo óptico, que permitem ao sistema estimar a profundidade e a velocidade relativa dos objetos em movimento (Dai et al., 2020)

Com base na velocidade do veículo e na distância para o obstáculo detectado, o sistema calcula o tempo de colisão (TTC - Time to Collision). Se o TTC for inferior a um limite de segurança predefinido, o sistema dispara alertas visuais e sonoros para o motorista. Em sistemas mais avançados, a intervenção pode ser automática, acionando a frenagem de emergência para evitar ou mitigar a colisão (Zhou et al., 2020).

- Integração com Frenagem Automática

Se o sistema anticolisão detectar uma ameaça iminente e não houver resposta do motorista, ele pode ativar automaticamente os freios para reduzir a velocidade do veículo ou parar completamente. Esse mecanismo é conhecido como Frenagem Automática de Emergência (AEB - Automatic Emergency Braking) e é uma aplicação comum de sistemas baseados em câmeras em veículos autônomos e assistidos (Shi et al., 2019).

O uso de câmeras para a AEB tem se mostrado eficaz na redução de acidentes em estradas urbanas, onde a detecção rápida de pedestres e veículos próximos é essencial para evitar colisões a baixa e média velocidade (Liu et al., 2021).

3.3 Limitações em sistemas de prevenção de colisão

Os sistemas de prevenção de acidentes oferecem potenciais benefícios, mas enfrentam certas limitações. Eles dependem fortemente da combinação de vários sensores, tais como câmeras e radares, que podem ser comprometidos por condições climáticas adversas, como chuva forte ou neblina, reduzindo drasticamente sua eficácia. Além disso, a confiança excessiva dos motoristas nesses sistemas, pode levá-los a adotar comportamentos mais arriscados, acreditando que estão sempre protegidos.

Outro desafio é a capacidade da IA de lidar com situações complexas e imprevisíveis, onde motoristas humanos costumam ter melhor desempenho. Embora os sistemas de IA estejam melhorando, ainda não são infalíveis, e erros podem ter consequências severas. Apesar dessas questões, é evidente que os sistemas de prevenção de colisões e veículos autônomos têm o potencial de reduzir significativamente os acidentes nas estradas.

Com mais pesquisas, podemos esperar melhorias na segurança rodoviária, e será interessante acompanhar a evolução desses sistemas e seu impacto no futuro do transporte.

4 Conclusão

Os sistemas de prevenção de colisões baseados em câmeras representam uma inovação crucial na segurança veicular, contribuindo significativamente para a redução de acidentes. Utilizando câmeras de alta resolução e algoritmos avançados de visão computacional, esses sistemas conseguem detectar com precisão pedestres, veículos e obstáculos em tempo real, fornecendo ao motorista alertas antecipados ou ativando a frenagem automática em situações de emergência. A integração com tecnologias de frenagem de emergência automática (AEB) torna esses sistemas ainda mais eficientes, especialmente em cenários urbanos de tráfego intenso, onde a rápida detecção de ameaças é essencial.

Utilizar câmeras em redes veiculares é apenas o começo. Para criar sistemas realmente robustos, é crucial combinar esses sensores visuais com outros tipos, como LIDAR, radar e sensores ultrassônicos. Essa combinação permite um sistema de anticolisões mais confiável, compensando as limitações de cada sensor individualmente.

5 Referências bibliográficas

- (i) Liu, J., Chen, Z., & Fang, F. (2021). Multisensor Data Fusion in Autonomous Driving Systems: A Survey on Camera, LiDAR, and Radar Integration. *IEEE Transactions on Intelligent Transportation Systems*, 22(3), 1338-1350.
- (ii) Ren, S.; He, K.; Girshick, R.; Sun, J. Faster R-CNN: Towards real-time object detection with region proposal networks. *IEEE Trans.*
- (iii) Redmon, J.; Farhadi, A. YOLO9000: Better, Faster, Stronger. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, Honolulu, HI, USA, 21–26 July 2017; pp. 6517–6525
- (iv) Dai, W., Zhang, Y., & Wu, S. (2020). Stereo Vision-Based Lane Detection and Tracking for Autonomous Vehicles. *IEEE Transactions on Vehicular Technology*, 69(8), 8472-8482.
- (v) Zhou, X., Liu, Y., & Wang, H. (2020). Deep Learning for Object Detection and Tracking in Autonomous Vehicles. *Journal of Advanced Vehicle Engineering*, 12(4), 241-256.
- (vi) Shi, Z., Gao, L., & Han, X. (2019). 360° Camera Systems for Autonomous Vehicles: A Comprehensive Review. *Sensors*, 19(18), 4023-4035.
- (vii) Pranjali A. Chitale; Kaustubh Y. Kekre; Hrishikesh R. Shenai; Ruhina Karani; Jay P. Gala. (2020). Pothole Detection and Dimension Estimation System using Deep Learning (YOLO) and Image Processing. *International Conference on Image and Vision Computing New Zealand*.
- (viii) Redmon, J., Divvala, S., Girshick, R., Farhadi, A. (2016). You Only Look Once: Unified, Real-Time Object Detection. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 779-788.
- (ix) Redmon, J., Farhadi, A. (2017). YOLO9000: Better, Faster, Stronger. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 6517-6525.